

Análise do desempenho da inteligência artificial generativa na detecção de pedidos de voto antecipados na redes sociais de políticos

Daniella Glaete ¹, Júlio Coutinho ²

and Marcos Antônio³

Universidade Federal Rural de Pernambuco, Recife-PE, Brasil

Abstract. In Brazilian elections, an increasingly common target of complaints is the use of social media to commit electoral violations. Many political actors use their social media profiles as campaign tools to increase their persuasive power and voter conversion. The most serious offenses involve requesting votes in advance during a non-election period, in which political actors are reported to the Electoral Court for the assessment of the violation. The greatest challenge for the Electoral Court today is being able to monitor all complaints and impose the appropriate penalties. The objective of this research is to investigate the effectiveness of different Generative AI approaches for identifying electoral violations from videos, in which the transcripts are evaluated by various AI models using different prompt structures. Once the most effective prompt structure and Generative AI model are identified, the goal is to help the Brazilian Electoral Court and other oversight bodies in the process of monitoring and sanctioning violations of Brazilian law, in order to discourage political actors from committing this offense.

Keywords: Generative AI, electoral violations, social media, electoral oversight.

RESUMO. Nas eleições brasileiras, um caso cada vez mais comum de denúncias é o uso das redes sociais para cometer infrações eleitorais. Muitos políticos utilizam seus perfis nas redes sociais como ferramentas de campanha para aumentar seu poder de persuasão e a conversão de eleitores. As infrações mais graves envolvem o pedido antecipado de votos durante um período não permitido, no qual políticos são denunciados à Justiça Eleitoral Brasileira para a apuração da infração, onde seu maior desafio é conseguir monitorar todas as denúncias e aplicar as penalidades adequadas. O objetivo desta pesquisa é investigar a eficácia de diferentes abordagens de IA Generativa para identificar infrações eleitorais em vídeos, nos quais as transcrições são avaliadas por vários modelos de IA com diferentes estruturas de prompt. Uma vez identificados a estrutura de prompt e o modelo de IA Generativa mais eficazes, o objetivo é auxiliar a Justiça Eleitoral brasileira e outros órgãos de fiscalização no processo de monitoramento e punição de violações da legislação brasileira, a fim de desencorajar políticos a cometer essa infração.

Palavras chaves: Inteligência Artificial, Violação eleitoral, Redes Sociais, Supervisão eleitoral.

1 INTRODUÇÃO

O avanço das redes sociais transformou profundamente a comunicação política, ampliando a capacidade de candidatos políticos de se aproximarem do eleitorado, divulgarem mensagens e construírem estratégias de persuasão em larga escala. No contexto eleitoral, essa presença digital deixou de ser apenas complementar e passou a influenciar visibilidade, engajamento e desempenho político, como evidenciado pela correlação entre métricas de redes sociais e resultados eleitorais observada no pleito presidencial brasileiro [2]. Ao mesmo tempo, esse ambiente digital passou a ser utilizado como espaço para a disseminação de conteúdos enganosos, práticas abusivas e possíveis violações da legislação eleitoral, o que impõe novos desafios ao monitoramento institucional e à proteção da integridade do processo democrático [1].

No contexto brasileiro, o uso de mídias sociais em campanhas eleitorais consolidou-se como componente central das disputas políticas. A literatura mostra que o crescimento de seguidores e o desempenho em plataformas como Instagram, Twitter e Facebook podem se associar de maneira significativa ao desempenho eleitoral, reforçando o peso estratégico dessas plataformas nas campanhas contemporâneas [2]. Contudo, essa mesma infraestrutura comunicacional também favorece condutas ilícitas, como o pedido antecipado de votos, a propaganda irregular e outras formas de influência indevida sobre o eleitorado [1].

Com base nesse cenário, este trabalho investiga o uso da Inteligência Artificial (IA) generativa para apoiar a identificação de possíveis infrações eleitorais em vídeos publicados no Instagram por políticos que já foram alvo de investigações judiciais. Para isso, realizou-se inicialmente um levantamento junto à Justiça Eleitoral brasileira de processos envolvendo políticos investigados pelo uso irregular de redes sociais no período pré-eleitoral, cujas penalidades previam a aplicação de multa caso os vídeos permanecessem publicados. A partir dessa busca jurisprudencial, coletou-se um conjunto de vídeos provenientes de dois perfis ativos de políticos no Instagram, caracterizados por publicações frequentes tanto sobre gestão pública quanto sobre temas diversos. Após a triagem do material audiovisual desses dois perfis, selecionou-se um total de 108 vídeos, dos quais 89 não continham pedidos de voto e 19 apresentavam pedidos explícitos de voto. Estes últimos foram coletados no período eleitoral permitido e incluídos para fins de análise aprofundada, visto que, devido às sanções judiciais, os vídeos originais que geraram as denúncias precisavam ser removidos para evitar a execução das multas. Posteriormente, procedeu-se à transcrição dos áudios por meio do modelo Whisper, da OpenAI, convertendo o conteúdo audiovisual em formato de texto para viabilizar a análise subsequente com os modelos de IA generativa.

Em seguida, foram definidas três estratégias de prompt para orientar os modelos na tarefa de identificação de possíveis irregularidades: *one-shot*, *few-shot* e *Chain-of-Thought*. O objetivo dessa etapa foi verificar de que forma diferentes estruturas de instrução poderiam influenciar a qualidade, a consistência e a capacidade interpretativa das respostas produzidas pelos modelos, considerando que estudos anteriores já apontam a importância do desenho do prompt no desempenho de sistemas generativos aplicados à análise de conteúdos eleitorais [1].

A etapa analítica utilizou, via API, três famílias de modelos de IA generativa. A primeira foi composta por duas versões do Gemini, Gemini 2.5 Flash e Gemini 2.5 Pro. A segunda incluiu duas versões do GPT, GPT-4o e GPT-4o mini. A terceira foi formada por duas versões do DeepSeek, DeepSeek V4 Flash e DeepSeek V4 Pro. A comparação entre diferentes modelos e versões buscou identificar quais combinações apresentavam maior potencial para apoiar uma triagem inicial de conteúdos suspeitos em ambiente eleitoral digital.

Diante disso, este estudo busca identificar a estratégia de prompt e o modelo de IA mais eficazes para a análise das transcrições dos vídeos com indícios de infração eleitoral. A proposta é contribuir para o desenvolvimento de abordagens automatizadas que possam auxiliar a Justiça Eleitoral e outros órgãos de controle no monitoramento de conteúdos publicados em redes sociais, considerando, de um lado, a relevância crescente da presença digital para o sucesso eleitoral e, de outro, a necessidade de respostas mais eficientes diante de possíveis ilícitos praticados nesse ambiente [1, 2].

2 Fundamentação Teórica

2.1 Redes Sociais e Performance Eleitoral

As redes sociais passaram a ocupar posição central nas campanhas políticas contemporâneas, não apenas como canais de divulgação, mas como espaços estratégicos de construção de imagem, mobilização e interação com o eleitorado. No caso brasileiro, evidências mostram que métricas de desempenho digital, como crescimento de seguidores e engajamento em plataformas, apresentam correlação com resultados eleitorais, indicando que a presença online pode influenciar significativamente a competitividade dos candidatos [2]. Esse cenário reforça a necessidade de compreender as redes sociais não apenas como meios de comunicação, mas como componentes relevantes da dinâmica eleitoral.

A centralidade dessas plataformas também amplia o potencial de uso indevido em contextos eleitorais. A mesma infraestrutura que favorece alcance, personalização e rapidez na circulação de mensagens também pode facilitar a disseminação de propaganda irregular, conteúdos enganosos e práticas de persuasão fora dos limites legais. Por isso, o ambiente digital se tornou um espaço prioritário tanto para campanhas legítimas quanto para a ocorrência de possíveis infrações eleitorais [1, 2].

2.2 IA generativa no monitoramento eleitoral

O avanço recente da Inteligência Artificial generativa ampliou as possibilidades de automação na análise de conteúdos digitais, incluindo tarefas de classificação, interpretação textual e identificação de padrões. No campo eleitoral, esse potencial é particularmente relevante porque o volume de publicações em redes sociais torna inviável uma análise exclusivamente manual por parte dos órgãos de controle. Além disso, a literatura mostra que modelos generativos podem atuar de forma ambivalente: tanto podem ser usados para intensificar estratégias de manipulação onde a maioria dos trabalhos se encontram e desinformação quanto podem servir como instrumentos de detecção e defesa [3, 5].

No contexto deste trabalho, interessa especialmente o uso da IA generativa como ferramenta de apoio à triagem de conteúdos suspeitos. [1] demonstram que modelos generativos, combinados com estratégias adequadas de prompt, podem contribuir para identificar irregularidades eleitorais em conteúdo de campanha. Esse achado é importante porque sugere que a IA pode apoiar etapas iniciais de fiscalização, oferecendo rapidez, escalabilidade e padronização analítica em cenários marcados por grande volume de dados [1].

2.3 Estratégias de Prompt e modelos de performance

O desempenho de sistemas generativos não depende apenas do modelo escolhido, mas também da forma como a tarefa é apresentada. Estudos recentes têm mostrado que diferentes estratégias de prompt podem alterar substancialmente a qualidade das respostas, influenciando precisão, contextualização e capacidade de raciocínio. Em aplicações de análise automatizada, isso significa que a formulação da instrução deixa de ser um detalhe operacional e passa a constituir parte essencial do método [1].

No caso da identificação de possíveis infrações eleitorais, essa questão se torna ainda mais relevante porque a interpretação do conteúdo exige sensibilidade contextual e aderência a critérios normativos. Estratégias como *one-shot*, *few-shot* e *Chain-of-Thought* oferecem diferentes níveis de orientação ao modelo, podendo afetar sua capacidade de reconhecer elementos discursivos associados a ilícitos eleitorais. Dessa forma, a comparação entre diferentes estruturas de prompt é necessária para avaliar quais combinações geram respostas mais consistentes e úteis para o contexto de monitoramento [1].

2.4 Lacunas na pesquisa

Embora a literatura já reconheça a relevância das redes sociais para o desempenho eleitoral e a utilidade potencial da IA generativa na análise de conteúdos digitais, ainda há uma lacuna específica quanto ao uso desses modelos em vídeos de políticos investigados por possíveis infrações eleitorais. Também são limitados os estudos que comparam, em um mesmo desenho experimental, diferentes famílias de modelos e distintas estratégias de prompt aplicadas a transcrições de fala em contexto eleitoral [1, 2].

Nesse sentido, este trabalho busca aproximar duas necessidades que estão frequentemente aparecem separadas nas literaturas: de um lado, a análise da centralidade das redes sociais quanto ao processo eleitoral; de outro, o desenvolvimento de soluções para a detecção de irregularidades. Ao testar múltiplos modelos de IA generativa sobre transcrições de vídeos reais, a pesquisa procura contribuir para uma abordagem metodológica mais aplicada ao contexto da fiscalização eleitoral digital [1, 2].

3 Metodologia

3.1 Desenho da pesquisa

Esta pesquisa adota uma abordagem aplicada e exploratória, com foco na avaliação do uso de modelos de Inteligência Artificial generativa para a identificação de possíveis infrações eleitorais em vídeos publicados por políticos no Instagram. O desenho metodológico foi estruturado para comparar diferentes modelos e diferentes estratégias de prompt em uma mesma base de dados, permitindo observar variações de desempenho analítico em condições controladas.




Fig. 1. Visão geral do fluxo de trabalho metodológico: coleta de dados, transcrição automática com Whisper e avaliação com CHAT GPT, Gemini e DeepSeek sob diferentes estratégias de estímulo.

A proposta metodológica foi organizada em quatro etapas principais: coleta dos vídeos, transcrição automática do conteúdo de fala, elaboração das estratégias de prompt e análise comparativa das respostas geradas pelos modelos. Esse encadeamento permitiu transformar conteúdo audiovisual em entradas textuais padronizadas, adequadas à avaliação por modelos de linguagem de grande escala. A Figura 1 exibe um exemplo aplicado.

As perguntas de pesquisa foram formuladas da seguinte maneira:

- **RQ1:** Quais modelos de IA generativa são mais eficazes para detectar possíveis infrações eleitorais em transcrições de vídeos?
- **RQ2:** Em que medida estratégias de prompt mais elaboradas produzem análises mais consistentes e úteis do que instruções mais diretas em tarefas de análise automatizada de possíveis infrações eleitorais?

3.2 Coleção do Vídeo

A etapa inicial da pesquisa consistiu na coleta de conteúdos audiovisuais publicados no Instagram por dois políticos que figuravam como polos passivos em procedimentos de investigação judicial eleitoral. A

seleção do corpus documental orientou-se pela busca de materiais com relevância jurídica e eleitoral material, priorizando publicações que apresentassem indícios de propaganda irregular, pedidos extemporâneos de voto ou outras condutas passíveis de sanção e controle por parte da Justiça Eleitoral brasileira.

A escolha por essa amostragem empírica, baseada em postagens reais, teve como objetivo aproximar a análise das situações concretas de fiscalização, preservando a estreita relação entre a linguagem política, o contexto discursivo e a possibilidade de infração. Dessa forma, a base de dados utilizada foi utilizada para simular de maneira fiel um cenário prático real de aplicação de ferramentas para o monitoramento eleitoral digital verdadeiro.

3.3 Transcrição da fala

Após a coleta, todos os vídeos foram submetidos a transcrição automática por meio do modelo Whisper da OPEN IA. Essa etapa teve como finalidade converter o conteúdo audiovisual em texto, permitindo que as falas presentes nos vídeos fossem processadas de forma homogênea pelos modelos de IA generativa avaliados no estudo.

A utilização do Whisper foi importante para padronizar a entrada de dados entre os diferentes modelos analisados. Em vez de comparar respostas sobre arquivos audiovisuais em formatos variados, a pesquisa passou a operar com transcrições textuais, o que tornou a avaliação metodologicamente mais consistente e comparável entre as diferentes famílias de modelos de IA generativa.

3.4 Estratégias de Prompt

```
One-Shot

prompt = f"""Analise o transcrito e determine se ha pedido de
voto. Responda obrigatoriamente neste formato JSON:
{{"pedido": "SIM" ou "NAO", "justificativa": "explicacao"}}
```

Fig. 2. One-Shot Prompt

Few-Shot Prompting

```
prompt = f"""Analise o transcrito e determine se há pedido de voto ou propaganda eleitoral direta. Exemplos de Referência:

Exemplo 1 (SIM - Explícito): Texto: 'Olá amigos, aqui é o candidato 44. Peço seu voto no domingo para mudarmos nossa cidade.' Resposta: {{\\"pedido\\": \\"SIM\\", \\"justificativa\\": \\"O orador menciona explicitamente seu número e solicita o voto diretamente.\\"}}

Exemplo 2 (SIM - Implícito): Texto: 'Precisamos de renovação. No dia da eleição, lembre-se de quem sempre esteve com você. Vote consciente, vote no nosso projeto.' Resposta: {{\\"pedido\\": \\"SIM\\", \\"justificativa\\": \\"Embora não cite número, utiliza jargão eleitoral ('vote no nosso projeto') caracterizando pedido de apoio nas urnas.\\"}}

Exemplo 3 (NÃO): Texto: 'Hoje estivemos na rua fiscalizando as obras da prefeitura. É um absurdo o atraso no saneamento básico.' Resposta: {{\\"pedido\\": \\"NAO\\", \\"justificativa\\": \\"O texto contém uma crítica política e fiscalização, mas não solicita voto ou apoio eleitoral.\\"}} Agora analise o texto abaixo: Texto: {texto[:5000]}

Responda obrigatoriamente no formato JSON: {{\\"pedido\\": \\"SIM\\\" ou \\"NAO\\", \\"justificativa\\": \\"explicacao\\"}}"""
```

Fig. 3. Few-Shot Prompt

Chain-of-Thought

```
prompt = f"""Analise o transcrito abaixo seguindo estes passos:

1. Identifique os principais tópicos abordados no texto.
2. Verifique se há menção a nomes de candidatos, números de urna ou coligações.
3. Analise se há verbos de ação que incitem o eleitor (ex: vote, escolha, apoie, confirme).
4. Determine se o contexto geral é de prestação de contas, crítica política ou propaganda eleitoral direta/indireta.
5. Conclua se há um pedido de voto.

Texto: {texto[:5000]}

Responda obrigatoriamente no formato JSON:

{{\\"analise_passo_a_passo\\": \\"descreva aqui seu raciocínio seguindo os pontos acima\\", \\"pedido\\": \\"SIM\\\" ou \\"NAO\\", \\"justificativa_final\\": \\"resumo da decisão\\"}} """
```

Fig. 4. Chain-of-Thought Prompt

Com as transcrições prontas, foram elaboradas três estratégias de prompt para orientar os modelos na tarefa de identificar possíveis infrações eleitorais: one-shot, few-shot e chain-of-thought. A estratégia one-shot consistiu em uma instrução direta com a descrição da tarefa, sem exemplos adicionais. A estratégia few-shot acrescentou exemplos de referência para orientar o padrão esperado de resposta. Já a estratégia chain-of-thought buscou induzir o modelo a desenvolver um raciocínio mais detalhado e progressivo antes de apresentar sua conclusão.

A adoção dessas três estratégias teve como objetivo analisar se diferentes níveis de contextualização e orientação afetariam a capacidade dos modelos de reconhecer elementos linguísticos e discursivos associados a ilícitos eleitorais. Considerando a sensibilidade contextual desse tipo de análise, a comparação

entre prompts foi tratada como parte central do experimento.

3.5 Modelos avaliados

$$\text{Total of Experiments} = \underbrace{(2 + 2 + 2)}_{\text{Gemini GPT DeepSeek}} \times \underbrace{3}_{\text{Strategies}} = 18$$

Fig. 5. Total de experimentos calculados.

A análise foi realizada com três famílias de modelos de IA generativa, todas acessadas via API. A primeira família foi composta por duas versões do Gemini: Gemini 2.5 Flash e Gemini 2.5 Pro. A segunda incluiu duas versões do GPT: GPT-4o e GPT-4o mini. A terceira foi formada por duas versões do DeepSeek: DeepSeek V4 Flash e DeepSeek V4 Pro.

A escolha desses modelos buscou contemplar versões com diferentes perfis de custo, velocidade e capacidade analítica. Ao comparar famílias distintas e versões internas de cada família, o estudo procurou identificar quais combinações seriam mais promissoras para a tarefa de triagem inicial de conteúdos eleitorais potencialmente irregulares.

Cada transcrição foi submetida aos modelos selecionados a partir das três estratégias de prompt definidas. Assim, para cada vídeo, foram geradas múltiplas respostas, permitindo comparar não apenas os modelos entre si, mas também o efeito da formulação do prompt sobre o resultado obtido. O foco da análise esteve na capacidade do modelo de reconhecer indícios de infração eleitoral no conteúdo transcrito.

A comparação das respostas considerou critérios como aderência à tarefa proposta, consistência interpretativa e utilidade para uma triagem preliminar de conteúdos suspeitos. O objetivo não foi substituir a análise jurídica humana de a caso, mas investigar o potencial da IA generativa como ferramenta de apoio ao monitoramento eleitoral, especialmente em contextos marcados por grande volume de dados e necessidade de resposta rápida nos pleitos eleitorais.

4 Resultados

4.1 Família de Modelos (RQ1)

Tabela 1. Métricas de desempenho por família de modelos

Família	Precision	Recall	F1 Score
GPT	0.924299	0.910494	0.914320
DeepSeek	0.898602	0.893519	0.895245
Gemini	0.908131	0.833333	0.849532

Na análise agregada por família de modelos, a família GPT apresentou o melhor desempenho médio, com $F1 = 0,9143$, seguida por DeepSeek ($F1 = 0,8952$) e Gemini ($F1 = 0,8495$). Esses valores indicam que, no contexto desta tarefa, os modelos GPT mantiveram melhor equilíbrio entre precisão e revocação na detecção de possíveis infrações eleitorais, enquanto DeepSeek apresentou desempenho próximo e Gemini mostrou maior variabilidade entre as combinações avaliadas.

4.2 Combinações de modelo e estímulo (RQ2)

Estratégia	Precision	Recall	F1 Score
One-shot	0.918585	0.902778	0.907016
CoT	0.904950	0.875000	0.882198
Few-shot	0.907497	0.859568	0.869883

Tabela 2. Desempenho médio por estratégia

Considerando apenas a estratégia de prompt, o melhor desempenho médio foi obtido com a abordagem one-shot, que alcançou $F1 = 0,9070$, superando as estratégias chain-of-thought ($F1 = 0,8822$) e few-shot ($F1 = 0,8699$). Em termos de precisão, o one-shot também se destacou, com valor médio de $0,9186$, ligeiramente superior às demais estratégias. Esses resultados sugerem que, ao contrário da expectativa inicial de que prompts mais elaborados produziram sistematicamente respostas superiores, a estratégia one-shot simples foi, em média, mais eficaz para a tarefa estudada, o que leva a uma resposta negativa parcial à RQ2.

4.3 Estratégias de Prompt (RQ2)

Family	Model	Strategy	Precision	Recall	F1 Score
DeepSeek	deepseek-v4-flash	CoT	0.925926	0.925926	0.925926
DeepSeek	deepseek-v4-flash	Few-shot	0.923846	0.907407	0.912106
DeepSeek	deepseek-v4-pro	One-shot	0.907407	0.907407	0.907407
DeepSeek	deepseek-v4-flash	One-shot	0.905695	0.898148	0.901001
DeepSeek	deepseek-v4-pro	CoT	0.864657	0.861111	0.862528
DeepSeek	deepseek-v4-pro	Few-shot	0.864078	0.861111	0.862499
GPT	gpt-4o	Few-shot	0.934716	0.925926	0.928602

Tabela

GPT	gpt-4o	One-shot	0.929697	0.925926	0.927357
GPT	gpt-4o-mini	Few-shot	0.929697	0.925926	0.927357
GPT	gpt-4o	CoT	0.918561	0.916667	0.917500
GPT	gpt-4o-mini	One-shot	0.922838	0.888889	0.897156
GPT	gpt-4o-mini	CoT	0.910284	0.879630	0.887949
Gemini	gemini25pro	One-shot	0.926868	0.898148	0.905188
Gemini	gemini25flash	One-shot	0.919003	0.898148	0.903985
Gemini	pro	Few-shot	0.922386	0.861111	0.874375
Gemini	gemini 25flash	CoT	0.902635	0.861111	0.872126
Gemini	pro	CoT	0.907639	0.805556	0.827156
Gemini	gemini25flash	Few-shot	0.870256	0.675926	0.714362

3.

Desempenho Médio Por Estratégia

Na análise por combinação específica de modelo e estratégia de prompt, o melhor resultado foi observado com a configuração GPT-4o associada ao prompt few-shot, que atingiu $F1 = 0,9286$, com precisão de $0,9347$ e revocação de $0,9259$. Combinações próximas incluem GPT-4o com one-shot e GPT-4o-mini com few-shot, ambas com $F1 = 0,9274$. Entre os modelos DeepSeek, destacou-se o deepseek-v4-flash com chain-of-thought, que alcançou $F1 = 0,9259$, com valores equilibrados de precisão e revocação. No caso dos modelos Gemini, a melhor combinação foi gemini25pro com one-shot ($F1 = 0,9052$), enquanto gemini25flash com few-shot apresentou desempenho substancialmente inferior ($F1 = 0,7144$), sobretudo em razão da revocação reduzida.

Esses resultados respondem diretamente à Q1, indicando que as combinações mais eficazes envolveram modelos da família GPT, em especial GPT-4o com prompts one-shot e few-shot, seguidos por configurações específicas de DeepSeek com chain-of-thought. Por outro lado, algumas variantes de Gemini mostraram forte sensibilidade à escolha da estratégia de prompt, com quedas expressivas de desempenho em determinados cenários.

4.4 Análise Comparativa de Desempenho por Modelo e Estratégia de Prompt




Fig. 6. Gráfico da unificação das estratégias

Com base nos gráficos, a análise de desempenho por combinação de modelo e estratégia de prompt revela que o GPT-4o (Few-shot) se destaca como a configuração de maior eficácia, alcançando um F1 Score superior e exibindo um equilíbrio notável entre Precision e Recall, conforme evidenciado no gráfico radar. O modelo DeepSeek-v4-flash com Chain-of-Thought (CoT) acompanha de perto, mostrando um perfil de desempenho similar ao líder e confirmando a eficácia do CoT para esta família de modelos. Em contraste, os modelos Gemini, embora o gemini25pro (One-shot) apresente excelente performance, demonstram maior sensibilidade à estratégia, com o gemini25flash (Few-shot) registrando um F1 Score significativamente menor devido a uma queda substancial no Recall. As estratégias One-shot e Few-shot geralmente oferecem resultados robustos, enquanto o CoT pode ser altamente eficaz, mas sua performance varia mais entre os diferentes modelos.

4.5 Análise por Combinação Específica





Fig. 7. Gráfico de análise completa

Na análise por combinação específica de modelo e estratégia de prompt, o melhor resultado foi observado com a configuração GPT-4o associada ao prompt Few-shot, que atingiu $F1 = 0,9286$, com precisão de $0,9347$ e revocação de $0,9259$. Combinações próximas incluem GPT-4o com One-shot e GPT-4o-mini com Few-shot, ambas com $F1 = 0,9274$.

Entre os modelos DeepSeek, destacou-se o DeepSeek-v4-flash com Chain-of-Thought (CoT), que alcançou $F1 = 0,9259$, apresentando valores equilibrados de precisão e revocação. No caso dos modelos Gemini, a melhor combinação foi o Gemini-2.5-pro com One-shot ($F1 = 0,9052$), enquanto o Gemini-2.5-flash com Few-shot apresentou desempenho substancialmente inferior ($F1 = 0,7144$), sobretudo em razão da revocação reduzida.

Esses resultados respondem diretamente à Q1, indicando que as combinações mais eficazes envolveram modelos da família GPT, em especial GPT-4o com prompts One-shot e Few-shot, seguidos por configurações específicas de DeepSeek com Chain-of-Thought. Por outro lado, algumas variantes de Gemini mostraram forte sensibilidade à escolha da estratégia de prompt, com quedas expressivas de desempenho em determinados cenários.

4.6 Interpretação da Importância de Features (Meta-Learning)



A aplicação de um modelo de Random Forest sobre as previsões dos LLMs permitiu identificar o peso relativo de cada família de modelos na composição de uma decisão consensual robusta. Esta técnica de Meta-Learning revela a confiabilidade intrínseca que o conjunto de dados atribui a cada classificador:

GPT-4o (Few-shot) como Pilar Central: O modelo GPT-4o apresentou a maior importância relativa (39,8%). Isso indica que, em casos de dúvida ou divergência entre os modelos, a previsão desta configuração específica é a que possui maior correlação com o acerto final (Ground Truth).

DeepSeek (CoT) como Complemento Estratégico: Com uma importância de 36,0%, o DeepSeek-v4-flash com Chain-of-Thought atua como um validador crítico, demonstrando que seu raciocínio estruturado é essencial para capturar nuances que outros modelos podem perder.

Gemini (One-shot) e Estabilidade: O Gemini 2.5 Pro contribui com 24,1%. Embora possua o menor peso entre os três líderes, sua presença é vital para a estabilidade do conjunto, servindo como uma base de comparação semântica direta e menos complexa.

4.7 Interpretação da Importância de Features (Meta-Learning)

Embora a análise quantitativa aponte a robustez de abordagens baseadas em Few-shot e One-shot com destaque para o desempenho do GPT-4o, a aparente superioridade dessas estratégias em detrimento do Chain-of-Thought evoca uma inconsistência teórica relevante. Teoricamente, o encadeamento de pensamento deveria sobressair-se ao lidar com nuances semânticas complexas. Para investigar essa anomalia metodológica, conduziu-se uma auditoria qualitativa apoiada em Inteligência Artificial Explicável (XAI), inspecionando detalhadamente as justificativas lógicas geradas pelos modelos em uma subamostra de

casos divergentes frente a um comitê de especialistas humanos.

Os resultados dessa auditoria revelaram a ocorrência de um viés de tagging (tagging bias) estrutural na base de dados original. Constatou-se que o tagging humano inicial tendeu a classificar os conteúdos de forma estritamente léxica, baseando-se na presença isolada de palavras-chave ou gatilhos visuais explícitos (como números de partidos ou termos imperativos de voto). Nesse cenário, a estratégia One-shot obteve métricas nominais elevadas de precisão e revocação não por uma compreensão semântica superior, mas por mimetizar com precisão o atalho heurístico (shortcut learning) e os vieses de simplificação contidos nos exemplos do gabarito.

Por outro lado, a aparente subperformance do método Cot nas métricas tradicionais decorre de uma penalização injusta imposta por um gabarito incompleto. A análise de explicabilidade evidenciou que, ao ser forçado a construir uma cadeia de raciocínio lógico antes da classificação, o modelo com CoT demonstrou maior sensibilidade a contextos implícitos e equivalentes semânticos de inconformidade — identificando termos de continuidade (como "nosso novo mandato" ou "mais quatro anos") como pedidos implícitos de voto. O modelo, portanto, divergiu do gabarito original para convergir com o Comitê Humano de revisão em 80% dos casos analisados (4 de 5 documentos), saneando falsos negativos e isolando falsos positivos gerados por enquetes neutras.

Sob a perspectiva metodológica, estes achados justificam a preterição temporária de arquiteturas mais complexas baseadas em meta-prompts ou validações multi-IA cruzadas. A introdução imediata de pipelines de múltiplos agentes sem o devido saneamento prévio da base de dados resultaria no fenômeno de "empilhamento de caixas-pretas", mascarando erros conceituais e elevando custos operacionais de forma ineficiente. Conclui-se, assim, que a explicabilidade via XAI cumpre um papel metodológico indispensável nesta pesquisa: o de atuar como ferramenta de auditoria e depuração do próprio ground truth, pavimentando o caminho para uma posterior otimização robusta da engenharia de prompts.

4.8 Avaliação geral

De forma geral, os resultados mostram que a abordagem proposta é capaz de alcançar níveis elevados de desempenho na detecção automatizada de possíveis infrações eleitorais em transcrições de vídeos. A combinação entre um corpus baseado em casos reais, o uso de transcrição automática e a avaliação comparativa de múltiplos modelos e estratégias de prompt permitiu identificar configurações com F1 próximo de 0,93, patamar compatível com o uso dos modelos como ferramenta de triagem inicial em fluxos de fiscalização. Ao mesmo tempo, a variação observada entre famílias de modelos e tipos de prompt evidencia a importância de decisões de configuração cuidadosas em aplicações práticas.

5 Conclusão

Este trabalho investigou o uso de modelos de Inteligência Artificial generativa para a identificação de possíveis infrações eleitorais em vídeos publicados por atores políticos no Instagram, com foco na propaganda eleitoral antecipada caracterizada por pedido de voto em período vedado. A partir de um corpus composto por vídeos de perfis sob investigação, transcritos com Whisper e analisados por diferentes famílias de modelos (Chat GPT, DeepSeek e Gemini) sob distintas estratégias de prompt (one-shot, few-shot e chain-of-thought), foi possível comparar o desempenho de múltiplas configurações em cenário próximo à prática de fiscalização.

Os resultados mostram que a metodologia proposta é capaz de alcançar índices elevados de desempenho, com combinações modelo–prompt atingindo F1 próximo de 0,93, o que torna plausível o uso desses modelos como ferramentas de triagem inicial em fluxos de monitoramento. A família GPT apresentou o melhor desempenho médio entre as famílias avaliadas, seguida de perto por DeepSeek, enquanto Gemini mostrou maior variabilidade de resultados. A análise das estratégias de prompt indicou que, em média, a abordagem one-shot foi a mais eficaz, ainda que, em configurações específicas, a estratégia few-shot tenha produzido o melhor resultado absoluto.

Do ponto de vista jurídico-eleitoral, a modelagem adotada dialoga diretamente com a disciplina normativa da propaganda antecipada. O art. 36-A da Lei nº 9.504/1997 estabelece que não configuram propaganda eleitoral antecipada, desde que não envolvam pedido explícito de voto, a menção à pretensa candidatura e a exaltação de qualidades pessoais de pré-candidatos, entre outros atos. A Resolução TSE nº 23.610/2019, com a redação dada pela Resolução TSE nº 23.732/2024, explicita que o pedido explícito de voto, para fins de configuração de propaganda extemporânea, não se limita ao uso da locução “vote em”, podendo ser inferido de termos e expressões que transmitam o mesmo conteúdo. Ao estruturar a tarefa de classificação em torno da detecção desses pedidos explícitos – textuais ou semânticos –, o estudo aproxima as capacidades atuais de modelos generativos da lógica de enquadramento jurídico construída pela legislação e pela jurisprudência eleitoral.

Como perspectiva de uso institucional, os achados sugerem que modelos de IA generativa podem ser incorporados como camada auxiliar de análise em sistemas de recebimento e triagem de denúncias, especialmente em contextos de grande volume de vídeos publicados em redes sociais. Não se trata de substituir a atuação da Justiça Eleitoral, mas de prover um mecanismo de apoio capaz de priorizar casos, reduzir o esforço manual e aumentar a qualidade da resposta dos processos eleitorais. Os Trabalhos futuros poderão ampliar o escopo das infrações analisadas, incorporar mais ainda e refinar os prompts para serem mais diretos e ampliar também o número de IA Generativa para analisar os diversos processos eleitorais.

Referências

1. Moura, S., Santos, E., Sampaio, P., Brito, K.: Using Generative AI for Identifying Electoral Irregularities on Social Media. In: Proceedings of DGO 2025 - 26th Annual International Conference on Digital Government Research, pp. 1–11. Pontifical Catholic University of Rio Grande do Sul, Porto Alegre (2025)
2. Brito, K.d.S., Meira, S.R.d.L., Adeodato, P.J.L.: Correlations of Social Media Performance and Electoral Results in Brazilian Presidential Elections. *Inf. Polity* (2021). <https://doi.org/10.3233/IP-210315>
3. Gilbert, C., Gilbert, M.A.: Leveraging Artificial Intelligence (AI) by a Strategic Defense against Deepfakes and Digital Misinformation. *Int. J. Sci. Res. Mod. Technol.* 3(11), 62–71 (2024)
4. Simchon, A., Edwards, M., Lewandowsky, S.: The persuasive effects of political microtargeting in the age of generative artificial intelligence. *PNAS Nexus* 3, pgae035 (2024)
5. Shoaib, M.R., Wang, Z., Taleby Ahvanooey, M., Zhao, J.: Deepfakes, Misinformation, and Disinformation in the Era of Frontier AI, Generative AI, and Large AI Models. In: Proceedings of the IEEE International Conference on Computer Applications (ICCA), pp. 1–7 (2023)
6. Wei, Z., Xu, X., Hui, P.: Digital Democracy at Crossroads: A Meta-Analysis of Web and AI Influence on Global Elections. In: Companion Proceedings of the ACM Web Conference 2024 (WWW '24 Companion), pp. 1–4. ACM, Singapore (2024)
7. Al-kfairy, M., Mustafa, D., Kshetri, N., Insiew, M., Alfandi, O.: Ethical Challenges and Solutions of Generative AI: An Interdisciplinary Perspective. *Informatics* 11, 58 (2024). <https://doi.org/10.3390/informatics11030058>
8. Dmonte, A., Zampieri, M., Lybarger, K., Albanese, M., Coulter, G.: Classifying Human-Generated and AI-Generated Election Claims in Social Media (2024)
9. Brasil. Lei nº 9.504, de 30 de setembro de 1997. Estabelece normas para as eleições. *Diário Oficial da União*, Brasília, DF, 1 out. 1997. Disponível em: https://www.planalto.gov.br/ccivil_03/leis/l9504.htm.
10. Tribunal Superior Eleitoral. Resolução TSE nº 23.610, de 18 de dezembro de 2019. Dispõe sobre propaganda eleitoral, utilização e geração do horário gratuito e condutas ilícitas em campanha eleitoral. Disponível em: <https://www.tse.jus.br/legislacao/compilada/res/2019/resolucao-no-23-610-de-18-de-dezembro-de-2019>.
11. Tribunal Superior Eleitoral. Resolução TSE nº 23.732, de 27 de fevereiro de 2024. Altera a Resolução TSE nº 23.610/2019, que dispõe sobre propaganda eleitoral, utilização e geração do horário gratuito e condutas ilícitas em campanha eleitoral. Disponível em: <https://www.tse.jus.br/legislacao/compilada/res/2024/resolucao-no-23-732-de-27-de-fevereiro-de-2024>.